

연구기관의 AX 실천적 모델

지표 설계부터 조직 내재화까지

백동천

한국기계연구원 AX Labs 연구실장

Open Source Tech Day 2026 · 2026. 10. 7.



CONTENTS

- 01 왜 지표인가 — 조직의 병목
- 02 KIMM AI Index — 설계와 결과
- 03 교육 → 제도 → 지표
- 04 내재화 — 보상 · 조직 · 인프라
- 05 함께 재면 서로의 거울이 된다



3년의 궤적

출연연 한 곳이 몸으로 실험한 기록 — 2024 교육 · 2025 제도 · 2026 지표

2024. 2

AI확산팀 신설

6개 부서 겸임 12명

교육·확산 원년 · 예산 2억

2025. 9

AX랩스 정규조직화

과제·가점 제도화

예산 2.5억 + GPU 13.9억

2026. 7

AX가속화연구단

11개 소·본부 겸임 34명

지표·내재화 · 예산 4.8억

교육으로 사람을 모으고 → 과제와 가점으로 행동을 유도하고 → 지표로 상태를 측정해 조직에 내재화한다



01

왜 지표인가 — 조직의 병목



01 개인은 쓰는데, 조직은 못 쓴다

AX의 병목은 모델이 아니라 조직이다

에이전트 실험 기업 **66%**

가치 실현 **10% 미만**

새는 곳 = 조직

80%

확장 장벽으로 데이터 한계를 지목한 기업

6%

AI 에이전트를 신뢰한다는 기업

40%+

2027년까지 프로젝트 취소 전망

조직 문제는 측정하지 않으면 보이지 않는다



1회 통과 ≠ 신뢰성

시연 1회 성공이 아니라, 활동이 아니라 상태를 반복 측정해야 한다

단일 실행



8회 모두 성공 (pass^8)



GPT-4o, τ -bench (Yao 외 2024) — 반복을 요구하면 신뢰도가 급락한다

조직의 AX도 같다.

시연 1회 성공이 아니라,
활동이 아니라 상태를
반복 측정해야 한다.

오늘의 관통선 — 측정 → 관리 → 환류



02

KIMM AI Index — 설계와 결과



KIMM AI Index — 6분야 × 5단계 × 180문항

연구기관용 진단 도구가 없어서, 직접 만들었다

분야 (가중치)

연구개발	30%	인재	20%
데이터	20%	인프라	10%
성과확산	10%	커뮤니티	10%

단계

- ⑤ 선도혁신
- ④ 조직내재화
- ③ 융합실행
- ② 활용기반 구축
- ① AI 인식

이중 측정

자가 인식(설문 180문항 O/X)
+ 실적 증빙(정량 22지표)
→ 인식-실적 괴리를 드러낸다

최종 KPI

논문 · 특허 · 기술료
— 기관의 본질 가치에 정렬

CMMI · KISTI RDM · MIT Sloan · KISDI — 4개 모델을 연구기관 맥락으로 통합




1.59 — 첫 측정의 결과

2025. 11 · 313/385명 응답(81%) · 5.0 만점

1.59

전체 평균 (5.0 만점)

하위 70%가 Lv 0-2 · 상위 그룹 5.7%
부서 간 격차 4.9배 (0.7 ~ 3.4)



AX는 사람의 문제가 아니라 구조의 문제다 — 개인(인재) 2.61 vs 조직(커뮤니티) 1.02



지표는 믿을 만한가, 무엇보다 투자하나

상관의 절반은 진단, 잔차의 절반은 처방

$r = 0.736$

부서 단위 인식 × 실적 상관 (R^2 약 54%) — 구성 타당도 확보

잔차 46%가 관리 대상

Shadow AI (실적 > 인식) → 가시화 · 소급 환류

과대평가 (인식 > 실적) → 실전 검증 · 멘토링

— 처방이 정반대다

실적과의 상관 (선행지표)



"사람을 더 뽑고 교육"보다
"실무에 AI를 박고 데이터를 정비"가 먼저



부서별 랭크 — 순위표가 아니라 좌표다

설문은 부서를 줄 세우기 위한 것이 아니라, 어긋난 부서를 찾기 위한 것이다

과대평가

인식 > 실적
실전 검증 · 멘토링

선도

상·하 모두 상위
전도사 역할 · 인증

초기탐색

둘 다 하위
지원 대상

Shadow AI

실적 > 인식
가시화 · 소급 환류

가로축: 정량 실적 지수 → · 세로축: 설문 인식 점수 ↑

부서 유형	수	랭크 해석
선도	1	상·하 모두 상위
균형성장	5	회귀선 위 정합
인재편중	7	인식이 실적을 앞섬
초기탐색	14	둘 다 하위, 지원 대상

같은 5위라도 회귀선 위인지 아래인지에 따라 처방이 정반대다. 순위만 공표하면 이 정보가 통째로 사라진다.



03

교육 → 제도 → 지표



교육 → 제도 → 지표

각 단계의 실패가 다음 단계를 낳았다

2024 · 대상 = 사람

교육으로 모은다

이수율 0%에서 측정 시작
워크숍 포맷 확보 · 수요 검증
교훈: 교육만으론 확산이 안 된다



2025 · 대상 = 행동

가점으로 움직인다

AI-Ready 13건(행정 3 포함)
교육·컨설팅 → 내부평가 가점화
교훈: 가점만으론 측정이 안 된다



2026 · 대상 = 조직

지표로 박아넣는다


AX-MVP 15건 · 경진대회 37팀
교육 이수율 53% (목표 20% 초과)
Index 대시보드 자동 집계

부수 실증 — AI 심사위원 PoC: 발표 음성 STT → LLM 평가, 5인 인간 심사위원 중간값과 유사



5.7%가 조직을 견인한다

개인을 교육하기보다, 전문가를 전도사로



5.7%의 전문가가 하위 70%를 끌어올린다

부서 유형 (27개)	처방
선도 1	전도사 역할 · 인증
균형성장 5	현 추세 유지 · 확장
인재편중 7	실무 적용 과제 연결
초기탐색 14	도메인 유스케이스 발굴

낙인 방지 — 부서 익명화, 하위 부서는 '지원 대상'으로 부른다



지표는 평가·보상에 닿아야 돈다

측정 → 공표만으로는 조직이 움직이지 않는다



지표가 월급봉투와 승진에 닿아야 조직이 돈다

2025 가점(교육시간 · 컨설팅 일지) → 2026 배지 · 크레딧(현상금 90점 + 크레딧 100점) — 3년의 제도 진화



조직의 일원에게는 '완결'이 오지 않는다

보상 설계가 어려운 진짜 이유 — 내 일이 끝나도 일이 끝나지 않는다

개인 작업 · 완결형

시작 → 완료 → 보상

루프가 닫힌다

조직 프로세스 · 미완결

내 구간 ... 끝은 남이, 훨씬 나중에, 다른 이름으로

완료 신호도 보상 신호도 오지 않는다

AX 과제가 멈추는 지점은 능력이 아니라, 끝냈다는 감각이 오지 않는 자리다

① 완료를 쪼갬다

박스 체크라도 만든다. 과제 단위를 주 단위 체크 리스트로 분해하면 체크 자체가 완결 신호가 된다

② 즉시 보이게 한다

디지털 배지. 승진·성과급보다 먼저 도착하는, 눈에 보이는 인정

③ 지연 보상을 잇는다

내부평가 크레딧이라도. K/S-Credit 200점. 체크가 결국 평가에 닿는다는 것을 보이게 한다

측정 → 인정 → 보상 사슬이 필요한 이유가 여기에 있다. 사슬이 끊기면 지표는 관찰기록으로만 남는다



04

내재화 — 보상 · 조직 · 인프라



04 내재화의 통로 — 겸임 TF와 에이전트

겸임 TF가 통로를 만들고, 에이전트가 동료가 된다

AX가속화연구단 ('26. 7 ~)

11개 소·본부 겸임 34명 · 3팀

AX혁신 · 지식플랫폼 · AX내재화

전담 조직이 아니라, 부서에 발을 걸친 TF가 내재화의 통로
부서 VoC 25건 → 우선순위 → 현상금 과제

에이전트 = 디지털 인력

Agent 원규(결재·기안권) 검토

에이전트 디지털 신원 부여 실험

에이전트가 조직도와 규정에 들어오는 순간,
'에이전트의 신뢰성'은 인사·감사의 문제가 된다

그래서 다음 질문 — 그 에이전트를 어떻게 믿을 것인가



인프라의 실체

'인프라'라는 단어가 실제로 가리키는 것



7 → 100

물리 GPU → 논리 분할 · 가용성 14배

13.9억

2025 인프라 예산 · 자체연구사업

왜 분할인가

연구자 대다수의 작업은 GPU 한 장을 다 쓰지 않는다. 병목은 점유가 아니라 대기시간이었다.


왜 온프레미스인가

미공개 연구데이터와 내부 문서를 외부 API에 태울 수 없다. 데이터 거버넌스가 인프라의 형태를 결정했다.



5개년 로드맵 — Measure에서 Lead까지

기관 경영목표로 편입 · 전 부서 최소역량 목표제



⚠ 최대 위험 구간

2026 → 2027 +0.5

목표 상향 구간의 리스크까지 명시하는 것이
신뢰성다운 계획이다

2025 실적

1.59 (목표 1.4 초과)

측정 원년에 목표를 넘겼다. 다음은 전 부서
최소역량 목표제



에이전트 실행 신뢰성의 3단 관리

양산 라인의 관리 체계를 그대로 이식한다

① 수입검사

모델 · 프롬프트 · 하네스 변경 = 4M 변경
pass^k 수락 기준 (예: pass⁸ ≥ 90%)
LLM 채점기는 Gage R&R 먼저



② 공정관리 (SPC)

성공률 p-관리도 · 환각 c-관리도
드리프트는 CUSUM / EWMA
자율 수준을 관리도 상태와 연동



③ FRACAS

전 트레이스 로깅 → 원인분석
모든 고장을 회귀시험으로 환류
→ 신뢰성 성장

⚠ 비정상 고장분포(모델 무통보 변경) — 관리한계는 변경점마다 재설정 · "지금까지 잘 됐으니 믿는다"는 평가 격차 주의



거버넌스 · 표준 — 신뢰가 인프라가 되는 중

속이 능력 경쟁에서 신뢰·거버넌스 경쟁으로 이동했다

HITL은 타협 불가

성공 팀의 94%가 예산권 가진 지정 책임자 보유

MIT/Sloan, 30+ 산업 인터뷰

MCP → AAIF 기준 (Linux Foundation, 2025. 12)

경쟁사 8곳이 '신뢰가능 인프라'에 동석

AAIF(Agentic AI Foundation): 에이전트 개방 표준을 관장하는 중립 재단
부품 규격 체계의 시작

균형을 위한 단서

표준의 "신뢰가능"은 아직 미션 언어 단계

"AI가 인력을 대체한다"는 주장은 검증에서 기각(0-3) — 현 단계 증거는 일관되게 보강(augment)을 가리킨다



05

함께 재면 서로의 거울이 된다



필요기술 다섯 · 필요제도 다섯

기술 다섯보다 제도 다섯이 어렵고, 어려운 만큼 격차의 원천이다

필요기술

인프라

GPU 7→100 분할
공용 플랫폼 (가용성 14배)

데이터

문서 6,000종 · 120GB
임베딩 · AI-Ready 설계

하네스

검증 게이트 · 재시도
HITL 구조화

관찰가능성

지표 자동집계 · 대시보드
상시 진단

표준 채택

MCP 등 개방 표준
형상관리 기반

필요제도

평가 연동

기여를 내부평가로
가점 → 배지 → 크레딧

책임 구조

named agent owner
HITL 게이트 명문화

에이전트 신분

Agent 원규
결재·기안권 · 신원

데이터 거버넌스

FAIR를 성과지표에
법무 트랙 사전 정비

변경점 관리

변경 시 수락시험
무통보 변경 방어



05 함께 재면 서로의 거울이 된다

절대 점수는 벤치마크가 있어야 의미를 갖는다



공유

180문항 풀셋 · 방법론 공개
「전자공학회지」 특집 2026. 4월호

확장

출연연 섹터 벤치마크 진행 중

→ 산학연 공통 문항 워크숍 제안

같은 문항으로 재야 서로의 좌표가 보인다

공동 어젠다

에이전트 도입 조직의 3단 관리

수입검사 → SPC → FRACAS를
지표와 함께 설계

지표 통합($\text{pass}^k \leftrightarrow \text{MTBF/FIT}$) · 비정상성 보
정 · 표준의 실효성

오픈소스 커뮤니티에 드리는 제안 — 문항 · 지표 · 대시보드를 열어 놓고 함께 짬시다

세 문장으로 마칩니다

1

AX는 사람의 문제가 아니라 구조의 문제다

개인 2.61 vs 조직 1.02

2

R&D와 데이터가 성과를 견인한다

그리고 지표는 평가·보상에 달아야 조직을 움직인다

3

조직의 AX는 측정 → 관리 → 환류의 루프다

열어 놓고 함께 짤 때 더 빨리 돈다

지표가 아니라 질문 목록을 가져가십시오 — 측정은 그다음입니다

감사합니다

연구기관의 AX 실천적 모델
백동천 · 한국기계연구원 AX Labs

