

오픈데이터의 생애주기 관리: 저작권 리스크 체크포인트

임솔지 변호사

LG AI 연구원 Legal&Compliance Team



CONTENTS

- 01 모델 파이프라인에 갇힌 논쟁
- 02 Bartz에 숨겨진 데이터셋 파이프라인
- 03 데이터셋은 순환한다: 생애주기 접근
- 04 단계별 접근과 활용






01

모델 파이프라인에 갇힌 논쟁

우리의 초점은 늘 모델이었다: source → train → service

AI 저작권 논쟁은 "학습이 공정이용인가", "출력에 학습데이터가 현출되는가"라는 모델 관점의 질문에 집중되어 왔습니다.



모델 파이프라인 위의 세 가지 질문

① train — 학습 복제는 공정이용인가?

학습을 위해 저작물은 복제한 행위가 변형적(transformative) 이용으로 정당화되는가

② weights — 모델이 저작물을 "담고" 있는가?

가중치가 저작물의 복제물·2차적저작물인가, memorization은 복제인가

③ service — 출력이 원작을 현출하는가?

출력물이 학습데이터를 그대로 재현(regurgitation)하면 침해인가, 누가 책임지는가

세 질문 모두 MODEL 띠 위에 있다.
아래의 DATASET 순환은 시야 밖에 있었다

최근 판례: 모델 단계에서 무엇이 쟁점이 되었나

판례마다 결론은 같지만, 다투어진 지점은 대부분 "학습 복제"와 "출력 현존"이라는 모델 파이프라인 위의 질문이었습니다.

사건	법원 · 시점	쟁점 위치	무엇이 다투어졌나 / 결과
Thomson Reuters v. Ross	미국 델라웨어 · 2025.2 (항소 중)	학습 복제	Westlaw 헤드노트를 경쟁 법률검색 AI 학습에 사용 → 공정이용 불인정
Kadrey v. Meta	미국 캘리포니아 북부 · 2025.6	학습 복제	LLM 학습은 공정이용 — 다만 "시장 희석(market dilution)" 논리도 다룬 결론 가능성
Bartz v. Anthropic	미국 캘리포니아 북부 · 2025.6 → 2026.7 합의	학습 복제 + 취득·보관	학습 = "극도로 변형적" 공정이용 / 해적판 취득·중앙 도서관 보관 = 침해 → \$1.5B 합의
Getty Images v. Stability AI	영국 고등법원 · 2025.11	가중치	모델 가중치는 저작물의 "침해 사본"이 아님 — 2차 침해 주장 기각 (학습 자체는 영국 밖이라 미판단)
GEMA v. OpenAI / v. Suno	독일 뮌헨 · 2025.11 · 2026.7 (항소 중)	가중치 + 출력	가사·음악의 memorization = 모델 내 복제, 출력 현존 = 침해
NYT v. OpenAI · Microsoft	미국 뉴욕 남부 · 진행 중	출력 현존	기사 원문이 출력으로 재현(regurgitation)된다는 주장 — 출력 단계가 핵심 쟁점
Disney · Universal v. Midjourney	미국 캘리포니아 중부 · 2025.6 제소	출력 현존	캐릭터 이미지 출력 — 출력물의 실질적 유사성이 쟁점

"AI copyright debates tend to begin too late."

모델이 학습되거나 출력이 생성될 즈음에는, 법적으로 의미 있는 복제 행위의 상당수가 이미 일어난 뒤입니다.



02

Bartz에 숨겨진 데이터셋 파이프라인

Bartz v. Anthropic 사건 개요

미국 캘리포니아 북부연방지법(Alsup 판사)은 "학습"과 "데이터 취득·보관"을 분리해 판단했고, 사건은 15억 달러 합의도 종결됐습니다.

2024. 8

작가 3인 집단소송 제기

도서를 무단 복제해 LLM 학습에 사용했다는
저작권 침해 주장

2025. 6. 23

약식판결(Summary Judgment)

- ① 합법 취득 도서 학습 = 공정이용
- ② 구입 도서 스캔 = 공정이용
- ③ 해적판 "중앙 도서관" 구축·보관 = 공정이용 아님

2025. 9

합의 발표 · 예비 승인

손해배상 재판 전 당사자 합의

2026. 7

합의 최종 승인

약 48.2만 건 저작물, 건당 약 3,000달러, 총
15억 달러 + 해적판 사본 파기 의무

\$1.5B

총 합의금 (미국 최대 저작권 합의)

~482K

대상 저작물 건수

~\$3,000

저작물 1건당

~7M

해적 사이트(LibGen·PiLiMi·Books3)에서
내려받은 도서 수

사람들이 기억하는 것은 "학습은 공정이용"이라는 첫 번째 결론입니다. 그러나 15억 달러는 그 결론에서 나온 것이 아닙니다.

사람들이 본 것 vs 판사가 본 것

모두가 모델 파이프라인(학습이 공정이용인가)에 집중했지만, 판사는 그 아래에서 책이 "복사되고, 보관되고, 도서관이 된" 과정을 보았습니다.

사람들이 본 것 — 모델 파이프라인

"책으로 LLM을 학습시킨 것이 공정이용인가?"

법원: 학습은 "극도로 변형적(exceedingly transformative)" — 읽고 배워 글을 쓰는 사람에 비유. 출처가 원작을 재현하지 않도록 하는 장치도 전제.

→ MODEL 파이프라인(source → train → service)는 통과

이 결론만 보면 "학습데이터 걱정은 끝났다"고 읽힙니다. 실제로 많은 보도가 그렇게 요약했습니다.

그러나 판결문의 분량과 손해배상의 전부는 다른 곳에 있었습니다.

판사가 본 것 — 숨겨진 데이터셋 파이프라인

복사 (copy)

Books3 · LibGen · PiLiMi에서 약 700만 권을 내려받음 — 취득 자체가 침해적 source

보관 (retain)

학습에 쓰고 버린 것이 아니라 영구 보관. "어떤 용도든" 쓸 수 있는 상태

도서관화 (library)


"도서관(library)" 구축이 그 자체도 별개의 이용. 학습의 공정이용이 이를 소급 정당화하지 못함

대조군: 구입·스캔

종이책을 사서 해체·스캔하고 원본은 폐기한 것은 transformative use → 공정이용.

판결을 그림에 얹어 보면

MODEL 파이프라인은 통과했고, 문제는 전부 DATASET 순환의 source와 store 노드에서 발생했습니다.



MODEL 파이프라인 — 통과

학습(train)은 별개의 "이용"으로 떼어 4요소 적용.
출덕(service)이 원작을 재현한다는 주장은 없었음.

Source — 취득 경로

같은 책이라도 구입하여 직접 스캔한 경우는 합법적인 source
해적 사이트 다운로드하는 그 자체도 침해.
하류의 공정이용이 상류의 불법 취득은 세탁하지 못함.

Store — 보관 목적·기간

보관(store)이 학습(train)에 종속된 중간 단계가 아니라
독립된 목적을 가진 별개의 이용으로 평가됨.
합의 조건에 해적판 사본 파기가 포함.




03

데이터셋은 순환한다: 생애주기 접근

모델은 흘러가고, 데이터셋은 순환한다

모델 파이프라인은 한 방향으로 끝나지만, 데이터셋은 저장·재배포·파생은 거쳐 다시 source로 돌아옵니다 — 개인정보의 흐름과 같은 구조입니다.



개인정보 생애주기와의 대응

수집 Collection		source
적법 근거 · 최소수집	↔	권리 근거 · 출처 추적
이용 Use		train
목적 범위 내 이용	↔	라이선스 범위 내 학습
저장 Storage		store
안전성 확보조치	↔	메타데이터 · 접근동제
제공·위탁 Transfer		share
제3자 제공 동의	↔	재배포 시 의무 전파
파기 Destruction		-
지체 없이 파기	↔	비가역성

한 번 수집되면 끝이 아니라 계속 흐른다 —
그래서 "흐름 전체"를 관리해야 한다

왜 생애주기(Lifecycle) 접근이 필요한가

학습데이터는 생애주기 관리를 통한 사전 동제의 필요성이 더 큼니다.

개인정보와 같은 조건

흐른다

원천 → 수집 → 가공 → 학습 → 배포 → 파생 데이터도 끝없이 순환

한 단계의 실패 = 전체 책임

원천 하나의 라이선스 위반이 모델 전체의 법적 지위를 흔들 (Bartz)

증명해야 한다

EU AI Act 학습데이터 요약 공개, 소송에서의 출처 입증 — "증명 가능성"을 요구

개인정보보다 더 필요한 이유

1

다층적 이해관계자

저작권자 · 라이선서 · 파생 제작자 등
다양한 이해관계자가 하나의 데이터셋에 겹침

2

재귀적 상속 구조

데이터셋이 데이터셋을 낳는 트리
상류 제약이 하류도 누적 전파

3

비가역성

학습 후 분리가 어려움
사전적 동제가 중요

4

형성 중인 규제

EU AI Act · 각국 판례가 진행 중
자율적 생애주기 관리 = 규제 대응 준비

생애주기 관리로 얻는 것: 출처 흐름도(provenance tree) · 단계별 통제항목 · 설명 책임(accountability)의 입증



04

단계별 접근과 활용

단계별 접근 ① source: 데이터 수집 단계의 리스크와 기록

데이터셋을 직접 만들 때 데이터가 들어오는 경로마다 리스크가 다르고, 그 시점에만 확보할 수 있는 기록이 있습니다.

수집 경로	주요 리스크	왜 기록이 필요한가 — 무엇을 남길 것인가
웹 크롤링 · 스크래핑 Web crawling	표현적 저작물(기사·도서·사진·음악)이 성격을 가리지 않고 대량 혼입. 이용약관의 크롤링·AI 학습 금지 위반(계약 책임), 접근동제 우회(망 침입), TDM 오프아웃 무시, 공개 개인정보의 목적 외 수집, 불법 콘텐츠 혼입(LAION), 해적 사이트 취득(Bartz).	웹은 계속 바뀐다. 수집 당시 약관 · robots.txt · 오프아웃 표시 · 페이지 내용은 나중에 확인할 수 없음 → URL · 수집 시각 · 약관 스냅샷 · 라이선스 표시를 기록해야. 없으면 삭제 요구 · 침해 주장 시 해당 노드를 찾을 수 없음.
합성 · 모델 생성 데이터 Synthetic	생성에 쓴 모델의 약관이 그대로 상속(경쟁 모델 학습 금지, 출력 상업 이용 제한). 원 모델이 암기한 표현이 출력에 섞여 제3자 저작물 재유입. 출력물의 저작권 지위 불명확 → 권리 근거 표시 곤란. 원 모델 학습데이터의 제약이 간접 승계될 수 있음.	출처가 없어 보여서 가장 쉽게 "깨끗한 데이터"로 오인된다. 어떤 모델 · 버전 · 약관 아래 어떤 프롬프트로 생성했는지 없으면 부모를 알 수 없음 → 기록해야 상속 제약과 영향 범위 추적 가능.
라이선스 구매 · 계약 Licensed	계약 범위가 좁음: 용도(연구/상용)·기간·지역·파생 모델 배포·종료 시 파기 의무 등 출처 불명·크롤링 수집물인 경우 혼하고, 벤더 보증은 원천을 추적했을 때만 의미. 계약 만료 후에도 모델에 남는 문제.	계약은 데이터와 따로 보관된다. 데이터가 어느 계약의 어느 조항에 묶였는지 연결해 두지 않으면 몇 년 뒤 상용 투입 가능 여부 · 만료 여부를 알 수 없음 → 계약 ID · 허용 용도 · 만료일 · 파기 의무 · 벤 더 출처 자료를 데이터에 부착.
자사 서비스 · 사용자 데이터 First-party	수집 시 고지 목적에 "AI 학습"이 없으면 목적 외 이용. 분쟁에서 '콘텐츠 제휴 약관'의 내용이 쟁점, 약관 개정의 소급 적용 논란. 이용자 콘텐츠 속 제3자 저작물, B2B 고객 데이터의 비밀유자·영업비밀. 오프아웃·삭제 처리 체계 부재.	동의 버전이 곧 적법 근거다. 이용자마다 가입 시점·동의 항목·처리방침 버전이 다르므로 데이터 단위도 동의 근거 를 연결해야 학습 투입 가능 여부를 판단하고, 오프아웃·삭제 요구 시 어느 데이터셋· 모델에 들어갔는지 찾을 수 있음 — 개인정보 동의 기록·파기와 유사.

단계별 접근 ② train: 비가역성 — 학습은 사실상 파기가 불가능하다

기계적 망각(unlearning)은 아직 신뢰할 수 있는 파기 수단이 아닙니다. 학습에 넣기 전에 "라이선스 범위 안인지"를 확인해야 합니다.

비가역성 (Irreversibility)

데이터 자체는 삭제가 가능하지만, 학습되고 나면 가중치에 녹아 있음

특정 데이터를 "빼내는" 유일한 확실한 방법은 그 데이터 없이 재학습

기계적 망각(unlearning)의 한계

제거 여부를 검증하기 어렵고, 성능 저하와 잔존(memorization) 위험이 남음

— GEMA 판결은 모델 내 잔존 자체를 복제도 봄

이미 배포된 가중치는 회수 불가

오픈 웨이트도 공개된 모델은 사후 파기가 사실상 불가능

라이선스 범위 내 학습 (Use within License)

목적 제한

연구용(research-only) · 비상업(NC) 데이터도 상용 모델 학습 금지

— 개인정보의 "목적 외 이용"과 같은 구조

AI 특화 조항

경쟁 모델 학습 금지, 출력 이용 제한(OpenRAIL 등)

— 데이터 배포와 무관하게 학습·모델 배포를 막는 조항

전처리 과정의 출처 유실

필터링·중복제거·병합 중에 원천 표시가 떨어져 나가면 이후 어떤 동제도 불가능

— 가장 흔한 실패 유형

단계별 접근 ③ store: 메타데이터 관리와 안전성 확보조치

Bartz에서 침해도 판단된 것은 학습이 아니라 "보관"이었습니다. 무엇을 왜 얼마나 보관하는지 기록하고, 접근을 통제해야 합니다.

메타데이터 관리 (Provenance Metadata)

출처

직계 소스 URL · 원천까지의 트리

권리 근거

라이선스 식별자 · 원문 링크 · 약관 전문

동일성 확인

해시 · 분변 스냅샷 · 버전

이력

수집일 · 수집 방법 · 전처리 기록

용도

어떤 모델·실험에 투입되었는가

제약

상속된 제한(NC-SA·연구) · 개인정보 포함 여부

안전성 확보조치 (Safeguards)

보관 목적·범위·기간 명시

"어떤 용도든 쓸 수 있는 영구 도서관"은 금지 — 학습 목적에 종속된 보관임을 기록으로 남김

접근권한 · 접근통제

최소 권한, 다운로드·복제 토그, 권한 회수 — 개인정보 안전성 확보조치 기준은 그대로 적용

복제본 통제

백업·테스트 DB·개인 작업 폴더에 방치된 사본이 사고의 시작 — 사본 위치를 대장에 포함

개인정보 혼입 관리

탐자·분리·가명처리 — 개인정보 생애주기 관리가 하위 절차도 포함됨

store 단계의 통제: 무엇을, 왜, 얼마나, 누가 접근할 수 있게 보관하는지 — 이 기록이 없으면 파기도, 설명도 불가능

단계별 접근 ④ share: 재배포 시 의무 전파, 합성데이터, 재귀적 상속

데이터셋이 밖으로 나가는 순간 의무가 하류도 전파되고, 모델 출력으로 만든 합성데이터는 그 모델의 약관까지 물려받습니다.

재배포 시 라이선스를 붙이는 세 가지 원칙

1. 내가 가진 권리만큼만 붙일 수 있다

내 라이선스는 편집·구조·주석 층에만 미치고 콘텐츠 층(원권리자)에는 미치지 않음.
적용 범위를 명시하지 않으면 "CC BY"가 콘텐츠까지 깨끗하다는 뜻으로 읽힘.
잘못 붙인 라이선스는 하류 전체를 오염시킴.


2. 상류 제약의 최솟값이 내 라이선스의 상한이다

소스 중 가장 엄격한 조건이 상한.
SA → 동일·호환 라이선스만, NC → 상업 허용 불가, ND → 변형 재배포 불가.
호환되지 않으면 서브셋으로 분리하거나 제외.

3. 하나의 라이선스로 뭉뚱그리지 않는다

서브셋 단위도 license 필드를 두고,
데이터셋 전체에는 '각 서브셋의 license 필드를 따른다'고 명기.
편집·구조·주석 층에 미치는 내 라이선스는 구분해서 표기.

재귀적 상속 구조 (Recursive Inheritance)



하류 노드의 리스크 = 자기 라이선스 + 상류 전체의 제약.


표면 라이선스가 "상업 이용 가능"이어도 상류에 NC·SA·약관 제약이 숨어 있으면 그것이 상한이 된다.

내가 넘긴 데이터셋도 누군가의 상류가 된다.

— 내 표기가 부정확하면 그 오류가 하류로 누적 전파된다.

단계별 접근 ④ share: 오픈소스 코드와 오픈소스 데이터셋은 다르다

"오픈 데이터셋이니 오픈소스처럼 써도 된다"는 가장 흔한 오해입니다.



중복 제거와 필터링은 데이터를 더 깨끗하게 만들 뿐, 그 출처를 알려 주지는 않습니다.

이 공급망의 모든 단계는 기술적으로 정당했지만, 최종 모델에 이르렀을 때, 진짜 출처는 네 단계 위 데이터셋에 묻혀 상위 라벨에서는 전혀 보이지 않습니다.

결함은 최종 데이터셋에 있지 않습니다. 아무도 더 이상 들여다보지 않는 그 출발점에 있습니다.

단계별 접근 ④ share: 오픈소스 코드와 오픈소스 데이터셋은 다르다

"오픈 데이터셋이니 오픈소스처럼 써도 된다"는 가장 흔한 오해입니다.

소프트웨어

개발자가 정의한 로직 그대로 동작



검사 중...




source_code.py

```
import requests
import flask ..... 스캐너 탐지: flask 3.1.0.
: BSD-3-Clause.
```

위험이 특정 코드 라인에 분명하게 드러납니다

AI

학습한 패턴을 바탕으로 확률적으로 결과를 생성



검사 중...




train.py

```
model = load_model('weights.h5')
data = load_dataset("./corpus/")
train(model, data) ..... 스캐너에는 파일 이름만 보입니다.
```

어떤 코드 한 줄로도 위험을 알아낼 수 없습니다

단계별 접근 ④ share: 오픈소스 코드와 오픈소스 데이터셋은 다르다


"오픈 데이터셋이니 오픈소스처럼 써도 된다"는 가장 흔한 오해입니다.



단계별 접근 ④ share: 오픈소스 코드와 오픈소스 데이터셋은 다르다

"오픈 데이터셋이니 오픈소스처럼 써도 된다"는 가장 흔한 오해입니다.

상업적으로 이용 가능하다고 판단된 2,852개의 AI 학습 데이터셋에 대해 종속 데이터의 리스크를 모두 고려해 본 결과, 21.21%인 605개의 데이터셋만 상업적으로 이용 가능했습니다.



이렇게 관리하면 어디에 쓰이는가

단계별로 기록된 데이터셋 생애주기는 조달·개발·보관·배포의 네 국면에서 그대로 재사용되는 자산이 됩니다.

Procurement

조달 · AIBOM (AI Bill of Materials)

- 외부 데이터셋·모델 도입 시 구성요소와 권리 근거를 부품표처럼 요구·검토
- 소프트웨어 SBOM 경험을 데이터셋으로 확장
- 벤더가 제공하지 못하면 도입 리스크

Development

개발 · 데이터셋 분리 관리

- source · 권리 · 이용 제한별 데이터셋은 분리 (연구용/상용, NC/상업, 개인정보 포함/비포함)
- 용도별 학습 풀을 구성해 "섞이는" 사고 방지
- 실험 단계부터 노드 기록

Retention

보관 · 어디에 썼고 어떻게 보관 중인지

- 어떤 모델·버전에 어떤 노드가 들어갔는지 추적
- 사본 위치·보관 목적·기간·접근 권한 기록
- 철회·삭제 요구 시 영향 범위를 즉시 산출

Deployment

배포 · 규제기관·투자자 실사 대응

- EU AI Act 학습데이터 요약, 출처 설명 자료
- 투자·M&A 실사에서의 데이터 권리 입증
- 분쟁 시 "어디서 어떤 근거로 가져와 어떻게 썼는가"의 설명 책임

논쟁은 모델에서 시작하지만, 통제는 데이터셋에서 시작해야 합니다.

개인정보 생애주기 관리가 신뢰의 인프라가 되었고, 학습데이터 생애주기 관리는 모델의 법적 안정성을 뒷받침하는 기반입니다.

감사합니다.

오픈데이터의 생애주기 관리:
저작권 리스크 체크포인트

