

AI, 클라우드, 디지털 주권을 잇는 오픈인프라의 미래

Open Infrastructure for the Age of AI, Cloud, and Digital Sovereignty

조성수

NHN Cloud 선임




CONTENTS

01 오픈인프라란 무엇인가?

02 오픈인프라의 지난 1년의 변화

03 AI 시대의 오픈소스 인프라 생태계의 변화





01

오픈인프라?



01 오픈인프라 (OpenInfra)

컴퓨팅, 스토리지, 네트워킹 등 IT 인프라의 다양한 형태를 모두 아우르는
오픈소스를 통합해 IT 인프라 환경을 구축하는 생태계



다양한 벤더와 기술 간
상호 운용성 확보



사용자 중심의
기여 기반 개발 방식



특정 기업에 종속되지 않는
자율적 운영 능력



OpenInfra Standard - LOKI



Linux

Open Source Operating System Standard



Openstack

Open Source Cloud Standard



Kubernetes

Open Source Container Orchestration Standard



Infrastructure



OpenInfra Standard

The OpenInfra Standard Adoption Growth

LOKI Implementation Continues to Rise, Supported by Increased Adoption of Magnum

Linux OpenStack Kubernetes Infrastructure (LOKI) is being implemented in production at an increasing rate as the OpenInfra standard. **Kubernetes is now deployed on over 85% of OpenStack deployments: 73% through vanilla Kubernetes and an additional 12% through OpenShift.** The rise in OpenStack and Kubernetes production integrations is further documented by an increase to 21% (up from just 16% last year) of users running production workloads with Magnum, the OpenStack service for container orchestration.




OpenInfra Standard



출처: <https://www.openstack.org/user-survey/2022-user-survey-report>




OpenInfra Project



OpenStack

Programmable
infrastructure for
VMs, containers
and bare metal



Kata Containers

Secure, lightweight
CRI-compatible
virtualized
containers



StarlingX

Edge cloud
computing
infrastructure



Zuul

CI/CD platform for
gating changes
across multiple
systems/repos



StarlingX

| 엣지(Edge) 클라우드 환경에 최적화된 오픈소스 인프라 플랫폼


초저지연·고신뢰성·대규모 확장성을 충족해야 하는 미래 지향적 서비스의 핵심 인프라로 각광받고 있음

5G 통신

산업 IoT

스마트 팩토리

자율주행





StarlingX 사용 사례 - Wind River

StarlingX를 기반으로 한 Wind River Cloud Platform을 제공하고 있다



엣지 운영 자동화

수만 개의 엣지 노드와 복잡한 분산 클라우드 네트워크를 자동화·지능화하여 운영할 수 있도록 지원한다.



AI/ML 기반 관리

예를 들어, AI/ML 기반의 분석 및 자동 의사결정 기능으로 대규모 인프라를 효율적으로 관리할 수 있다.

사용 사례

글로벌 통신사

Verizon, Vodafone, T-Systems 등 글로벌 통신사들이 StarlingX를 기반으로 수천~수만 개의 5G 기지국 및 엣지 클라우드 인프라를 구축·운영한다.

Boost Mobile

Boost Mobile 역시 VMware에서 Wind River Cloud Platform(StarlingX 배포판)으로 전환하여, 엔터프라이즈, 코어 통신 인프라, O-RAN(개방형 무선접속망) 등 다양한 영역에 적용

01 Zuul

오픈소스 기반의 CI/CD 및 프로젝트 게이팅 시스템

CI/CD: Continuous Integration / Continuous Delivery

게이팅(Gating)

코드 변경 사항이 실제로 병합되기 전에, 해당 변경이 **모든 연관 프로젝트와 함께 테스트를 통과해야만 병합**이 되는 시스템



효과

프로젝트 게이팅 시스템으로 여러 프로젝트 또는 마이크로서비스 간의 상호 의존성이 복잡한 환경에서도, **코드 품질과 안정성**을 효과적으로 보장할 수 있다



01 Zuul 활용 사례 - Volvo Cars



Zuul at Volvo Cars Corporation





01 Zuul 활용 사례 - Volvo Cars

1,000명+

동시 협업 개발자

수백 개

저장소

Zuul을 핵심 CI/CD 체인으로 도입하여, 1,000명 이상의 개발자와 수백 개의 저장소가 동시에 협업하는 대규모 소프트웨어 개발 환경에서 Zuul의 게이팅 시스템을 적극적으로 활용

주요 적용 분야

- 자율주행 소프트웨어, 차량용 중앙 컴퓨터, 다양한 차량용 소프트웨어 모듈 개발
- 'Speculative Merge(추측 병합)' 기능을 활용해, 코드 병합 대기 시간을 단축하고, 깨진 코드가 메인 브랜치에 병합되는 것을 방지

효과

- 코드 품질 향상
- 빌드 속도 개선
- DevOps 오버헤드 감소
- 개발자 경험 향상



02

오픈인프라의 지난 1년의 변화



OpenInfra Foundation의 LF 편입

2025년 3월 OpenInfra Foundation (OIF)는 급변하는 오픈소스 생태계에 유연하게 대응하기 위해 Linux Foundation에 편입한다고 발표했다.

The screenshot shows the OpenInfra Foundation website. The header is dark with the OpenInfra logo on the left and navigation links (PROJECTS, MEMBERSHIP, EVENTS, ABOUT, NEWS) in the center. On the right, there are 'LOGIN' and 'JOIN' buttons. The main content area is white and features a 'Blog' section with the subtitle 'OpenInfra Foundation news, announcements, best practices, use cases and more.' Below this, a large headline reads 'Open Infrastructure Foundation Board Announces Intent to Join the Linux Foundation to Amplify the Global Impact of Open Source'. The author is listed as 'By Allison Price on 12/03/2025'. The body text begins with 'AUSTIN, Texas, and SAN FRANCISCO, Calif., March 12, 2025— Today, the Linux Foundation, the nonprofit organization enabling mass innovation through open source, announced that the Open Infrastructure Foundation (OpenInfra) has signaled its intent to join as a member foundation, following unanimous approval from both the OpenInfra and Linux Foundation boards. Together, the Linux Foundation and the OpenInfra Foundation will unite their growing, vibrant, global ecosystems to empower users and developers with trusted open source solutions.'

출처: OpenInfra Foundation 블로그 (2025.3.12)



OIF의 LF의 합류 과정

합류 과정



합류 배경



달라진 시대적 요구

“2025년에 프로젝트가 재단에 필요로 하는 것은 2010~12년과 매우 다르다. 정부가 오픈소스에 깊이 관여하는 시대 — 정책을 이해하고 올바르게 대응해야 한다.” (Bryce)



역량 공유와 규모의 경제

LF의 성숙한 **법무·보안·정책·이벤트 인프라**를 공유하고 **중복 투자를 제거**.
2012년 오픈스택 재단 설립 당시엔 LF가 지금 같은 멀티 프로젝트 허브가 아니었음.



기술적 통합의 현실 반영

OpenStack의 80%가 K8s, 90%가 **Ceph**와 결합 운영한다.
이미 한 몸처럼 쓰이는 기술들의 거버넌스를 한 지붕 아래에서 큰 시너지효과를 발휘한다.



OpenInfra Blueprint

OpenInfra Foundation과 Linux Foundation은 OpenInfra Blueprint를 기반으로 이미 오래전부터 협업하고 있었다

Building the Open Infrastructure Blueprint: How Linux, OpenStack, and Kubernetes Combine to Deliver an Open Source Powered Infrastructure Stack

This collection of open source projects in particular has risen as a powerful top-to-bottom open source infrastructure stack.

Introduction

Open source has proven that it is as production ready as proprietary software. Open source has proven that it can scale and integrate with other technologies to reach the needs of almost any use case. One collection of open source projects in particular has risen as a powerful top-to-bottom open source infrastructure stack. This stack is made with Linux, OpenStack and Kubernetes. These open source projects are three of the top most active open source projects in the world.

출처: <https://openinfra.org/open-infrastructure-blueprint-white-paper>



OpenInfra Blueprint 핵심 가치



워크로드 통합

컨테이너, 가상머신, 베어메탈을 하나의 인프라에서 단일 솔루션으로 관리하여 **운영 오버헤드를 절감**합니다.

Container · VM · Bare Metal



상호 보완

K8s는 OpenStack의 자원을 활용하고, OpenStack은 K8s 위에서 클라우드 네이티브 운영 이점을 얻는 **양방향 아키텍처**를 구현합니다.

OpenStack on Kubernetes

Kubernetes on OpenStack



벤더 종속 탈피

라이선스 제약 없는 오픈소스로서 디지털 주권 확보를 위한 **독점 솔루션의 강력한 대안**이 됩니다.

디지털 주권 확보



최근 1년의 오픈인프라 생태계의 대표 키워드



디지털 주권

40%

Gazpacho 기여 중 유럽 비중

미국 하이퍼스케일러·독점 솔루션 의존 탈피가 유럽 전역의 정책 의제가 됐다. EU €1.8억 소버린 클라우드 입찰, 독일 SCS, 프랑스 NUBO 등 OpenStack 기반 사업이 늘고 있다.



VMware 전환

80%+

마이그레이션 요청을 받은 회원사

Broadcom 인수 후 라이선스 정책이 바뀌면서 VMware 이탈이 빨라졌다. OpenInfra 회원사 80% 이상이 요청을 받았고, 그중 60% 이상은 이미 전환을 마쳤다 (2025.3 보고서).



AI 워크로드

30%

AI/ML을 운영 중인 사용자 비율

2025 User Survey 응답자의 30%가 OpenStack 위에서 AI/ML 워크로드를 운영한다(이 중 60%가 유럽). GPU 스케줄링, 베어메탈, 컨피덴셜 컴퓨팅이 주요 요구사항이다.



02 VMware 마이그레이션의 주류가 된 OpenStack

회원사 80%가 요청, 60%는 전환 완료

OpenInfra 회원사 80% 이상이 VMware에서 OpenStack으로의 전환 요청을 받았고, 그중 60% 이상이 이미 전환을 마쳤다.¹

Rackspace: 고객 80%가 vSphere를 떠나는 중

Forrester도 VMware 운영 조직의 우선 대안으로 오픈소스를 꼽았다. Gartner는 2029년까지 VMware 점유율이 최대 30% 줄 수 있다고 본다.

Summit Europe 2025, 5개사 동시 이전 시연

Canonical, Rackspace, Worteks, Red Hat, ZConverter가 한 무대에서 VMware 워크로드 이전을 실시간으로 시연했다. 'VM Migration Day' 트랙도 따로 열렸다.

Gazpacho가 메우는 VMware 기능 공백

VMware 기능	OpenStack 대응
vMotion	→ Nova 병렬 라이브 마이그레이션
보안 VM 이동 (TPM)	→ vTPM 라이브 마이그레이션 (Barbican 연동)
DRS 자원 재배치	→ Watcher 크로스 존 마이그레이션
스토리지 정책 (SPBM)	→ Manila·Cinder QoS 타입
운영 콘솔	→ Skyline·Horizon, 지능형 기본값

1. OpenInfra, 'From VMware to OpenStack' 보고서 (2025.3) 2. 기관별 전망치로, 출처에 따라 차이가 있음



02 유럽이 이끄는 소버린 클라우드

커뮤니티의 중심이 유럽으로

OpenInfra 커뮤니티의 38% 이상이 유럽에 있고, Gazpacho 기여의 40%가 유럽에서 나왔다. Superuser Award 파이널리스트 5팀도 모두 유럽 조직이다.

정책과 예산이 실제로 움직이는 중

EU 집행위는 €1.8억 규모 소버린 클라우드 입찰에서 4개 컨소시엄(OVHcloud, STACKIT, Scaleway, Proximus 계열)을 뽑았다. 프랑스 NUBO, 독일 STACKIT도 OpenStack 기반이다.

SCS: 독일이 만든 소버린 클라우드 표준

Sovereign Cloud Stack은 독일 정부(BMWK) 지원으로 시작한 OpenStack+K8s 표준 스택이다. 지금은 OSBA 산하 표준 포럼이 이어받았고, OpenInfra의 글로벌 파트너로서 Gaia-X에도 기여한다.

OpenInfra Summit Europe 2025

파리 École Polytechnique · 10월 17-19일

65개국+ **1,200명+** **100+**

참가 국가

참가자

세션

- 주요 주제: AI, 디지털 주권, VMware 마이그레이션
- 키노트: ECMWF와 BT Group이 Blueprint 적용 사례 발표
- Carrez 키노트: “제가 AI를 한 번도 언급하지 않은 걸 눈치채셨나요?”라며 주권을 첫 번째 의제로 꼽음



03

AI 시대의 오픈소스 인프라 생태계의 변화



CNCF, OpenInfra, PyTorch 합동 컨퍼런스

세 오픈소스 커뮤니티가 처음으로 한 무대에 모였다

공식 명칭: KubeCon + CloudNativeCon + OpenInfra Summit + PyTorch Conference China 2026

CNCF

**KubeCon +
CloudNativeCon**

플랫폼 엔지니어링, 관측성, 네트워킹,
보안

Kubernetes

+

OpenInfra Foundation

OpenInfra Summit

Kata Containers, 가상화, 스토리지,
인프라 프로비저닝

OpenStack

+

PyTorch Foundation

PyTorch Conference

모델 학습과 추론, AI 가속기, 성능
최적화

PyTorch

일시

2026.9.7-9

9.8-9 본 행사

장소

중국 상하이

상하이 국제컨벤션센터

주최

리눅스 재단

3개 재단 공동 개최

화두

AI 운영 플랫폼

클라우드 네이티브와 AI의 결합



Open Source for the AI Era

| AI 시대 인프라의 초점은 표준화에서 긴밀한 통합으로 옮겨가고 있다

클라우드 시대

표준화 + API

환경을 최대한 표준화하고, API로 자원을 제공



AI 시대

긴밀한 통합

성능을 끌어내기 위해 하드웨어부터 에이전트까지 연결

오픈소스 커뮤니티는 이미 통합이 가능한 방향으로 움직이고 있다

OpenStack

IroniC

베어메탈 서버를 직접 제공

Kubernetes

DRA

GPU 등 가속기를 동적으로 할당

PyTorch


디바이스 비종속 API

특정 하드웨어에 묶이지 않는 API



AI 에이전트 시대의 인프라 변화

| CNCF CTO가 말하는 AI 에이전트 시대의 인프라



KEYNOTE

Operating Frontier Intelligence at Scale

Chris Aniszczyk
CNCF CTO

KubeCon + CloudNativeCon
China 2026

영상: https://www.youtube.com/watch?v=R-OiykDx_9M



AI 에이전트 시대의 인프라 변화

| 모델은 충분히 좋아졌고, 이제 질문은 '어떻게 운영하나'로 바뀌었다

01

모델 활용

특정 작업에 가장 좋은 모델을 어떻게 쓸 것인가

02

추론 운영

하이퍼스케일러부터 네오클라우드, 로컬까지 추론을 어떻게 운영할 것인가

03

연결

이 모든 것을 어떻게 이어붙일 것인가

세 질문의 공통점

분산 시스템의 문제

CNCF가 지난 10여 년간 다뤄 온 문제



AI 에이전트 시대의 인프라 변화

| 학습은 가끔 일어나지만, 추론은 끊임없이 일어난다

학습 (Training)

빈번하지 않음

모델을 만들고 개선하는 데 중요하지만 상대적으로 드물게 일어난다



추론 (Inference)

매우 빈번하게 일어남

에이전트나 프롬프트가 행동을 수행할 때마다 일어난다

메시지

“에이전틱 워크로드는 본질적으로 추론에 굶주려 있다”



AI 에이전트 시대의 인프라 변화

대규모 추론은 결국 분산 시스템이며, 클라우드 네이티브 원칙 위에서 구현된다

대규모 추론이 요구하는 것

오케스트레이션 트래픽과 워크로드

네트워크 · 관측성 문제 대응

스케줄링 작업 배치

클라우드 네이티브 원칙 위에 나란히 만들어지는 인프라

기존 · 애플리케이션 확장에 성공

- 컨테이너
- 마이크로서비스
- 불변·선언적 인프라

+

새로 · 에이전트를 위한 인프라

- 적절한 자원 격리와 샌드박싱
- 에이전트 간 프로토콜
- 모델 서빙

클라우드 네이티브 원칙



AI 시대의 인프라 변화에 맞춰

강조된 CNCF 프로젝트



Karmada

| 멀티 클러스터 오케스트레이션 Karmada, 이번 서밋에서 CNCF 졸업 선언

PROJECT

Karmada

여러 클러스터·클라우드·리전에
Kubernetes 앱을 수정 없이 배포·운영

CNCF Graduated

기여자 1,214명 · 기여 조직 292곳
GitHub Stars 5,600+

karmada.io

github.com/karmada-io/karmada

서밋에서 소개된 내용

CNCF 졸업 발표

9월 8일 상하이 행사 현장에서 CNCF 최고 성숙도 단계인 Graduated 달성 발표

v1.19 릴리스

분산 AI 학습의 멀티 컴포넌트 스케줄링 강화, 우선순위 스케줄링 Beta 기본 활성화

2026 로드맵

우선순위 선점, AI 학습·배치용 멀티 클러스터 큐잉, 가속기용 멀티 클러스터 DRA

사용 사례

Bloomberg

재해 복구 자동화, 자원
활용률 개선

Huawei · Trip.com

하이브리드 클라우드
용량, 멀티 리전 복원력

SenseTime 등

AI 학습, 클러스터 간
GPU/CPU 스케줄링



HAMi

앱 수정 없이 GPU를 쪼개 쓰고 격리하는 쿠버네티스 미들웨어

PROJECT HAMi

Heterogeneous AI Computing
Virtualization Middleware

CNCF Incubating

옛 이름 k8s-vGPU-scheduler
NVIDIA · Ascend · Cambricon 등

project-hami.io
github.com/Project-HAMi/HAMi

해결하는 문제

작은 작업도 GPU를
통째로 점유

벤더마다 다른 가속기
운영 방식

스케줄러가 모르는
디바이스 정보

핵심 기술

디바이스 공유
메모리·코어 단위로
GPU를 나눠 할당

리소스 격리
CUDA·NVML 호출을
가로채 할당량 강제

스마트 스케줄링
binpack·spread·토폴로지 인지 배치

동작 구조

Webhook
Pod 요청 변환

Scheduler
GPU 선택·배치

Device Plugin
장치 할당

HAMi-core
컨테이너 내 격리



HAMi - China Merchants Bank 사례

| HAMi로 가속기를 공유해 평균 활용률을 35%에서 60% 이상으로 올렸다

과제

같은 하드웨어, 서로 다른 요구

분산 학습

안정적인 용량이 필요하지만 나머지 워크를 기다리며 가속기가 놀기 쉬움

온라인 추론

예측할 수 없는 트래픽에 맞춰 빠르게 늘고 줄어야 함

멀티테넌트 파인튜닝

여러 팀이 같은 베이스 모델을 각자 띄워 자원 중복

해결: 인프라는 공유하고 런타임은 분리한 통합 아키텍처

Kueue

학습 작업 큐·쿼터 관리

KEDA + Prometheus

실시간 수요로 추론 확장

Fluid

데이터·모델 접근 가속

HAMi 학습·추론 양쪽에 가속기를 잘게 나눠 할당하는 공유 계층

Kubernetes · 이기종 가속기 약 10,000장

성과

60%+

평균 활용률 (기존 35%)

-60%+

토큰 100만 개당 비용

99%

통합 관리 가속기 비중

출처: CNCF 보도자료 'China Merchants Bank Wins CNCF End User Case Study Contest' (2026.9.8). 비용은 동일 모델·서비스 조건 기준



AI 에이전트 시대, 인프라의 새로운 모습



Kata Container의 재발견



Kata Container란?

| Kata Containers는 컨테이너의 속도에 VM 수준의 격리를 더한 런타임이다

기존 컨테이너와의 차이



기존 컨테이너
호스트 커널 하나를 공유
namespace·cgroup으로 프로세스만 분리

Kata Containers
워크로드마다 경량 VM과 전용 커널
VM 수준 격리·보안, 컨테이너의 속도·유연성은 그대로



에이전트 런타임: Kata Container의 재발견

| Kata Containers의 격리가 이제 에이전트 코드를 가두는 방호벽이 됐다

과거 · 클라우드

이웃 컨테이너 간 간섭 차단

멀티테넌트 환경의 마이크로VM 격리



지금 · 에이전트

에이전트가 만든 코드를 격리

위험한 코드로부터 호스트 커널·핵심 시스템 보호



SESSION

From Cloud to AI: How Kata Containers 4.0 Reinvents the Sandbox for the Agent Era

클라우드에서 AI로: Kata Containers 4.0이 에이전트 시대를 위해 샌드박스를 어떻게 재발명하는가

Fupan Li · Ant Group

샌드박스 기술의 르네상스를 알린 세션

영상: <https://www.youtube.com/watch?v=GP1C9y06kQo>

03

격리에서 기밀 컴퓨팅으로: GPU까지로 확대

| 기밀 컨테이너가 GPU를 지원하며 제로 트러스트 AI 인프라가 가능해졌다



KEYNOTE · 2일차

Road from Kata Containers to Confidential Containers and GPUs

Zvonko Kaiser · NVIDIA

영상: <https://www.youtube.com/watch?v=j-rxbpevEh8>

기존 한계

샌드박스 안에서는 GPU를 제대로 못 썼다
GPU 패스스루 성능 저하, 권한 제어 모델 충돌

변화

기밀 컨테이너가 GPU 통합을 지원

CNCF 인큐베이팅 진입, 메모리 암호화·TEE 위에서
GPU 연산 100% 활용

의미

호스트 관리자도 모델·데이터에 접근 불가

IP 보호에 민감한 금융·의료의 규제·보안 우려를 풀 열쇠

03

오픈소스로 만드는 AI 풀 스택

 AI Applications & Agents	 Agents  Harnesses  Applications  MCP	Agentic AI Foundation 개발자·조직의 AI 서비스
 Build & Serve Intelligence	 PyTorch  LLM  RAY	PyTorch Foundation 모델 학습·파인튜닝·서빙
 Operate & Scale AI Workloads	 Kubernetes  KServe  Kueue  OpenTelemetry  Istio	CNCF 대규모 실행·서빙·관측
 Infrastructure & Isolation	 OpenStack  Kata Containers	OpenInfra Foundation 인프라 제공과 제어
 Heterogeneous Compute	 NPU  CPU  GPU  기타 가속기	하드웨어 계층 AI를 움직이는 하드웨어

감사합니다

