

AI 시대의 오픈소스와 지식재산권의 충돌

Distillation Attack 사례를 중심으로

조희경

홍익대학교 법과대학

Open Source Tech Day

2026.10.07, Seoul



CONTENTS

- 01 들어가며
- 02 증류의 정의
- 03 지식 증류에서 "증류 공격"으로
- 04 법적 관점
- 05 마치며






01

들어가며



여러분이 이걸 한다면, 불법일까요?



어느 단계가 **불법**일까요?


"There are only two hard things in Computer Science: cache invalidation and naming things." — Phil Karlton



02

종류의 정의


'종류'란 무엇인가 — Teacher → Student



Teacher → Student 지식 전이 · Gou et al., Knowledge Distillation: A Survey, IJCV (2021), Fig. 1을 바탕으로 재 구성

Buciluă·Caruana, Model Compression (KDD 2006) · Hinton·Vinyals·Dean, "Distilling the Knowledge in a Neural Network", arXiv:1503.02531 (2015)

“증류”되는 것은 무엇인가 What is being “distilled”?



모델의 **행동을 모방**하는 것과 모델 **자체를 복제**하는 것은 같은 것인가?



03

지식 증류에서 "증류 공격"으로

Detecting and preventing distillation attacks

Feb 23, 2025

We have identified industrial-scale campaigns by three AI laboratories—DeepSeek, Moonshot, and MiniMax—to **illicitly extract** Claude's capabilities to improve their own models. These labs generated over 16 million exchanges with Claude through approximately 24,000 fraudulent accounts, in violation of our terms of service and regional access restrictions.

These labs used a technique called “distillation,” which involves training a less capable model on the outputs of a stronger one. **Distillation is a widely used and legitimate training method.** For example, frontier AI labs routinely distill their own models to create smaller, cheaper versions for their customers. **But distillation can also be used for illicit purposes:** competitors can use it to acquire powerful capabilities from other labs in a fraction of the time, and at a fraction of the cost, that it would take to develop them independently.

These campaigns are growing in intensity and sophistication.

The window to act is narrow, and the threat extends beyond any single company or region.

Addressing it will require rapid, coordinated action among industry players, policymakers, and the global AI community. ...

'증류 공격'의 워싱턴의 연대기

- 2026. 2.** 엔트로픽, 중국계 기업들의 '지식 증류 캠페인' 공개
딥시크·문샷AI·미니맥스 — 유명 계정 2.4만 개, 질의 1,600만 건
- 2026. 2.~** 구글·오픈AI도 유사 피해 발표
"산업적 규모의 증류 공격" 프레임 확산
- 2026. 4.** H.R. 8283 "미국 AI 모델 도난 방지법" 발의
추출 공격자 블랙리스트 → 수출통제 등재 → IEEPA 자산동결
- 2026. 6.** 엔트로픽, 상원 증언
알리바바 연구소 2,880만 건 → 1억 5천만 건 이상으로 상향
- 2026. 9.** NSA·CISA 합동 보안 권고
증류·추출 공격을 안보 범죄로 공식화

우리나라의 언론 보도

SBS 뉴스 · 2026. 7. 25.
"그만 **흠쳐!**" 클로드 폭발...'
또 중국이냐' 미국 뒤집은 **증류 수법**

뉴스1 · 2026. 9. 15.
[단독] AI '생각'까지 **빼갔다**
... 中 기업 '**불법 증류**' 수법 드러나

자본 · 2026. 7. 26.
"클로드 **흠쳐** 키미 만들었다"
... 美, '증류 공격'에 **제재 경고**

조선일보 · 2026. 9. 17.
"中이 AI 두뇌 **흠쳤다**" 美中
AI **패권전쟁 뇌관**으로 떠오른
'증류'

동아일보 · 2026. 4. 7.
딥시크 키운 '증류' 방식, 美
빅테크 '**무임승차**'에 **칼 빼들었다**

IT데일리 · 2026. 9. 11.
애틀로픽, 中 AI 7곳 '**불법 증류**' 지목... 클로드 기술 **빼내**
학습


KBS 뉴스 · 2026. 2. 13.
인공지능 노리는 **해커들**... 사
이버 추출, **증류 공격** 증가

데이터넷 · 2026. 7. 23.
'Kimi K3' 증류 논란 확산...
AI 모델 **탈취**가 새로운 **사이버 위협**으로

애플경제 · 2026. 9. 19.
글로벌 AI경쟁, "'증류'와의 **전쟁**" 본격화

115건의 뉴스 분석 — 프레임의 수입

국내 언론의 AI 종류 논쟁 헤드라인 프레임, 2026년 2~9월
빅카인즈 1년치(1,841건) 중 종류 논쟁을 헤드라인화한 기사 115건 · 저자 코딩 · 프레임 어휘(베끼기·탈취·도용·훔치다) 포함



주: 헤드라인 단위 분류. 전체 비율 A 70% · B 19% · C 3% · D 8%. 한국 입장(C) 4건은 전부 7월 지재처 국면. 3·5월은 각 1건. | 주요 계기 — 2월: OpenAI 메모·Anthropic 보고서 / 4월: 3사 공조·백악관 발언 / 6월: Anthropic 상원 서한(알리바바) / 7월: Kratsios·베센트 발언 + 지재처 보도 / 9월: 美 발표 + 中 반박(정상회담 국면)

미국 프레임 기사 80건 중 66건은 '종류' 대신 절도 은유(베끼기·탈취·도용·훔쳤다) —



04

법적 관점

다섯 개의 법적 렌즈

1 저작권법

AI 출력물은 "인간의 창작물"인가/ 모델 의 가중치는 저작물인가?

2 데이터베이스권

구조와 배열을 베꼈는가?

3 영업비밀

영업비밀을 "부정하게" 취득했는가?

4 이용약관 (계약)

집행 가능한 계약인가 — 공정성과 준거법?

5 부정경쟁방지법

타인의 성과를 가로챘는가?

① 저작권법

관할	저작권	영업비밀	계약으로 배제 가능한가
미국	Sega v. Accolade(9th Cir. 1992) · Sony v. Connectix(2000): 호환·기능 파악 목적 중 간복제 = 공정이용 · DMCA § 1201(f)	DTSA, 18 U.S.C. § 1839(6)(B): 역분석은 "부정한 수단" 아님	다툼 중 — Bowers v. Baystate(2003, 유효) ↔ 연방법 선점·남용론 (Henderson·Lemley)
EU	SW지침(2009/24) 5(3) 관찰·연구·시험권 · 6조 디컴파일 · SAS v. WPL(C-406/10): 기능·언어 비보호	영업비밀지침(2016/943) 3(1)(b): 적법한 취득	불가 — 8조: 배제 계약 무효(강행규정)
한국	저작권법 § 101조의3①6 조사·연구·시험 목적 복제 · § 101조의4 프로그램코드역분석	판례·통설: 정당 취득한 물건의 분석은 부정취득 아님	명문 없음 — 해석론의 영역(→ 강행규정 논의)

세 법제 공통의 원리: 표현이 아닌 아이디어·기능의 학습은 저작권 침해에 해당하지 않는다.

Output을 이용해 학습하면 저작권 침해인가?

1 Is the output itself a "work"?
→ 출력의 저작물성 (인간의 창작적 표현인가)

2 What exactly was copied?
→ 복제의 대상 — 표현인가, 사실·아이디어·기능인가

3 What copying happens during training?
→ 학습 과정의 복제 — 저장·전처리가 중치

4 Does the trained model copy the teacher model's protected original expression?
→ 결과물에 보호되는 원 저작물의 창작적 표현이 남아 있는가

표절과 저작권 침해가 다르듯, "모델을 베낀 것"과 저작권법상의 "불법 복제"는 동일하지 않다.

② 데이터베이스권

데이터베이스권이 보호하는 것

소재의 체계적 수집·분류·배열 → 구조

그 구조에 들어간 상당한 투자

※ 미국에는 독자적 DB권 자체가 없음

종류가 실제로 가져가는 것

- DB를 다운로드하지 않음
- 배열을 베끼지 않음
- 사용자로서 질문하고, 돌아오는 답변을 수집
- 답변은 고정된 데이터가 아닌 실시간 생성물

남의 데이터베이스를 베끼는 것이 아니라, 자기 데이터베이스를 새로 만드는 것

③ 영업비밀

필수 요건: 비밀로 관리될 것(비밀관리성) — 가중치와 내부 구조는 분명 비밀입니다

"비밀인 것은 가져가지 않았고, 가져간 것은 비밀이 아니다"

증류가 가져가는 것은 가중치가 아니라, 누구에게나 제공되는 API 답변

API는 대중에게 열린 문 — 공개된 문으로 들어와 답변을 관찰한 행위를

"부정한 수단에 의한 취득"이라 부를 수 있는가?

- 아직까지 법적 확답이 없는 질문

④ 계약법

OpenAI 이용약관 (공식 국문판, 2026. 1. 1.) ·
Anthropic Commercial Terms (2025. 6. 17.)

"...소스 코드나 기본 구성 요소를 리버스 엔지니어링,
디컴파일 또는 알아내려 하거나... 금지 (관련 법률에
서 이러한 제한을 금지하는 경우 제외)"

"자동으로 또는 프로그래밍 방식으로 데이터나 출력을
추출하는 행위" 금지

"OpenAI와 경쟁하는 모델을 개발하기 위해 출력을
사용하는 행위" 금지 · "...including to train
competing AI models" (Anthropic D.4)

Copyright infringement?

≠

Breach of contract?

저작권법상 허용 여부와

계약상 허용 여부는

서로 다른 문제이다

약관이 금지하면 그것이 우선하는가?

Not necessarily. 해석론의 문제

Can a contract prohibit what copyright law permits?

법은 허용하지만 약관이 금지하는, 예를 들어 저작물 아닌 것의 이용을 계약으로 막는 조항의 효력은 다툼 중 (Bowers ↔ 선점·남용론)

Can a contract exclude statutory exceptions?

EU: 불가 — SW지침 8조, DSM지침 7조1항이 명문으로 배제 계약을 무효화 · 한국: 명문 없음, 약관규제법 § 6·§ 11과 제한규정의 강행규정성으로 해석

Are there mandatory rules?

OpenAI 약관 스스로 "관련 법률에서 이러한 제한을 금지하는 경우 제외"라고 쓴다 · 관문: 준거법이 캘리포니아 → 국제사법상 국제적 강행규정 인정 여부

언제 진짜 'Attack'이 되는가?

	정상적인 API 사용	약관 위반	우회 / 침해
API 호출	✓	✓	✓
Output 수집·학습	✓	경우에 따라	경우에 따라
Rate limit 우회			✓
인증 우회			✓
허위 계정			✓
법적 결과	위법 없음	채무불이행 (효력 다툼)	정통방법 § 48① · CFAA · 제재

⑤ 부정경쟁방지법

영업비밀

비밀성

비밀로 관리되는 기술·경영 정보

(카)목 데이터 부정사용

거래성

업으로 제공되는, 축적·관리된 데이터
(2021 신설)

(파)목 성과도용

창출성

상당한 투자·노력으로 만든 성과

세 겹을 모두 갖춘 법제는 비교법적으로 한국이 사실상 유일

미국: 영업비밀 + 계약뿐 — 데이터 부정사용 조항도, 연방 차원의 성과도용 일반조항도 없음 (판례법상 misappropriation은 주법 차원에서 협소하게만 생존)

(파)목 — 마지막으로 남는 카드

"타인의 상당한 투자나 노력으로 만들어진 성과를 공정한 상거래 관행에 반하는 방법으로 무단 사용하여 경제적 이익을 침해하는 행위"

들어맞는 징표

- 대량·체계적 사용 — 수만 계정, 천만 건 단위 질의
- 동의와 대가의 부재
- 허용 범위를 넘는 초과 사용 (약관 위반)

한계

- 무제한 적용을 막기 위한 '고도의 위법성' 요구
- 그 기준은 아직 불명확 (선행 연구의 진단)
- 개인 이용자가 아닌 경쟁자의 행위일 때 유력

경쟁자의 대규모 증류라면 — 현행법상 가장 유력한 구제수단



남이 하면 절도, 내가 하면 공정이용?

프론티어 모델들도 타인의 상당한 투자와 노력의 성과인 방대한 저작물을 무단 학습해 성장

앤티로픽, 2026. 7. 저작권 침해 소송을 15억 달러 합의로 종결

미국 학계의 비판 — "이중 잣대", "사다리 걷어차기"

우리의 항로 — 세 가지 방향

1 국내 생태계 보호

소버린 AI에 투입되는 막대한 자본(국민 세금 포함)

유력한 방패는 부정경쟁방지법

단, 잣대는 모델의 국적이 아니라 행위에 있어서 일관된 원칙 적용 필요

2 기술적 방어

워터마킹·추출 탐지 — 여러
분의 영역

부당한 추출을 보여줄 수 있어야 법적 구제도 가능

3 현재는 방어보다 학습

선진 증류(advanced distillation) 역량

추론 과정·논리 구조를 최소 비용으로 이식

+ 특화 도메인의 AI 주권 방어

학생일 때나, 교사일 때나 — 무지의 베일

미국
프론티어 모델은
"재산"

중국
출력물 접근은
"정당한 경쟁 도구"

한국
"큐비트" - " 중첩 상태 "
학생(0)이자 교사(1)

대외적으로 우리는 아직 학생 — 그러나 국내에서는, 그리고 머지않아 대외적으로도, 증류당
할 수 있는 교사

자칫하면 상대에 따라 잣대를 바꾸는 내로남불이 되기 쉬운 자리

롤스의 "무지의 베일" — 어느 자리에 설지 모른 채 세워도 받아들일 수 있는, 명확하고 공정
한 기준이 필요하다



05

마치며



"파괴적 기술 앞에서, 폐쇄로 만든 해자는 일시적입니다.
우리의 해자는 함께 성장하며 노하우를 쌓는 팀, 혁신할 수 있는 조직과 문화입니다.
오픈소스는 상업적 행위라기보다 문화적 행위입니다."

— 량원평, 딥시크 창업자 (2024. 7.)


"우리가 역사의 잘못된 편에 서 있었는지도 모른다."

— 샘 올트먼, 오픈AI CEO (2025. 1., 딥시크 R1 직후)

명분은 추격자가 선점했고, 선두 주자는 인정할 수밖에 없었습니다

"파괴적 기술 앞에서, 폐쇄로 만든 해자는 일시적이다"

량원평 · 딥시크 창업자 · 2024



"우리가 역사의 잘못된 편에 서 있었는지도 모른다." 2025.01. 샘 올트먼, 오픈AI

참고자료

언론·기관자료

조선일보 (2026. 9. 17.)

https://www.chosun.com/economy/tech_it/2026/09/17/STCDCYJ45VB5HHQ2CM4CUJA14M/

YTN (2026. 9. 10.) https://www.ytn.co.kr/_ln/0104_202609101633492984

LA Times (2026. 9. 24.) <https://www.latimes.com/politics/story/2026-09-24/xi-in-lavish-trump-summit-urges-human-control-over-ai>

뉴스시스 (2026. 9. 22.) https://mobile.newsis.com/view/NISX20260922_0003799700

IISS Cyber Power Matrix (2026. 5.) <https://www.iiss.org/online-analysis/cyber-power-matrix/2026/05/ai-distillation-attacks-in-the-uschina-contest/>

Reuters (2026. 9. 10.) <https://www.reuters.com/legal/litigation/anthropic-disrupts-russian-chinese-ai-campaigns-targeting-its-claude-models-2026-09-10/>

NSA-CISA 합동 권고문 AA26-251A <https://www.cisa.gov/news-events/cybersecurity-advisories/aa26-251a>

H.R. 8283, Deterring American AI Model Theft Act

판례·법령

대법원 2010. 8. 26. 선고 2010다28185 판결; 대법원 2015. 3. 20. 선고 2012다118846 판결 — 법률신문 평석: <https://www.lawtimes.co.kr/news/articleView.html?idxno=104995>

저작권법 제101조의4; 약관규제법 제6조; 부정경쟁방지법 제2조 제1호 (가)·(파)목

학술문헌

Claudia Philipp, From Prompt to Clone: Copyright Challenges in AI Model Distillation, 17 UC L. SF Sci. & Tech. J., January 2026, at 49.

Henderson & Lemley, "The Mirage of Artificial Intelligence Terms of Use Restrictions", 100 Ind. L.J. (2025)

Parth Nobel, Alan Z. Rozenshtein & Chinmayi Sharma, Untangling AI Openness, 2026 Wis. L. Rev. 169 (2026). <https://doi.org/10.59015/wlr.MTYD1181>

"Stealing Prometheus's Fire: A Multi-Modality Framework for Regulating AI Knowledge Distillation" (2026)

김시현, "부정경쟁방지법상 AI 학습데이터 보호 체계에 관한 연구 — 영업비밀·데이터 부정사용·성과도용의 기능 분담을 중심으로", 강원법학 제83권 (2026. 5.), 295–372면.

이상훈, "AI 모델 증류에 대한 부정경쟁방지법상 형벌 공백의 구조와 형사화의 한계 — 정상 이용과 접근통제 우회의 구별을 중심으로", 법이론실무연구 제14권 제3호 (2026. 8.), 469–496면. <https://doi.org/10.30833/LTPR.2026.08.14.3.469>

감사합니다.

